

# 第7章： 贝叶斯学习

蒋良孝



中国地质大学（武汉）



CUG-Miner

机器学习与数据挖掘团队

**ljiang@cug.edu.cn**

<http://grzy.cug.edu.cn/jlx/>



# 本章内容

**一、贝叶斯学习基础知识**

**二、贝叶斯最优分类器**

**三、朴素贝叶斯分类器**

**四、朴素贝叶斯分类器改进**

# 一、贝叶斯学习基础知识

- 用 $P(h)$ 表示在没有观察到训练数据之前假设 $h$ 拥有的初始概率， $P(h)$ 被称为假设 $h$ 的先验概率。
- 先验概率反映了关于假设 $h$ 是一正确假设的机会的背景知识；如果没有这一先验知识，可以简单地将每一候选假设赋予相同的先验概率。
- 类似地， $P(D)$ 表示训练数据 $D$ 的先验概率，那么 $P(D|h)$ 就表示假设 $h$ 成立时 $D$ 的概率。
- 在分类问题中，我们关心的是 $P(h|D)$ ，即给定 $D$ 时 $h$ 的成立的概率，称为 $h$ 的后验概率。

# 一、贝叶斯学习基础知识

- 交换规则：  $P(A, B) = P(B, A)$
- 乘法规则：  $P(A, B) = P(A|B)P(B) = P(B|A)P(A) = P(B, A)$
- 贝叶斯定理：  $P(h|D) = P(D|h)P(h)/P(D)$
- 全概率法则： 如果事件  $A_1 \dots A_n$  互斥，且满足：

$$\sum_{i=1}^n P(A_i) = 1, \text{ 则 } P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

# 一、贝叶斯学习基础知识

- 贝叶斯定理提供了从先验概率 $P(h)$ 、 $P(D)$ 以及 $P(D|h)$ 计算后验概率 $P(h|D)$ 的方法


$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- $P(h|D)$ 随着 $P(h)$ 和 $P(D|h)$ 的增长而增长，而随着 $P(D)$ 的增长而减少。这是很合理的，因为如果 $D$ 独立于 $h$ 时被观察到的可能性越大，那么 $D$ 对 $h$ 的支持度就越小。

# 一、贝叶斯学习基础知识

- 贝叶斯网络，也叫贝叶斯信念网，是一种用来表示变量间连续概率的有向无环图模型，图中的节点表示变量，有向边表示变量间的依赖关系，依赖关系的强弱用标识在边旁边的条件概率来表示。
- 贝叶斯网络表示一组变量的联合概率分布。

$$P(A, B, C, D) \equiv P(A|B, C, D)P(B|C, D)P(C|D)P(D)$$



贝叶斯网络学习

结构学习  
参数学习

$$P(A, B, C, D) = P(A)P(B|A)P(C|A)P(D|B, C)$$

## 二、贝叶斯最优分类器

<div>→ m</div>					
Instance ID	A <sub>1</sub>	A <sub>2</sub>	...	A <sub>m</sub>	C
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

n

→

a<sub>1</sub>

a<sub>2</sub>

...

a<sub>m</sub>

c=?

$$c(x) = \arg \max_{c \in C} P(c|a_1, a_2, \dots, a_m)$$

↓  
贝叶斯定理

$$c(x) = \arg \max_{c \in C} \frac{P(a_1, a_2, \dots, a_m|c)P(c)}{P(a_1, a_2, \dots, a_m)}$$

↓  
全概率法则

$$c(x) = \arg \max_{c \in C} \frac{P(a_1, a_2, \dots, a_m|c)P(c)}{\sum_c P(a_1, a_2, \dots, a_m|c)P(c)}$$

↓  
**NP-Hard Problem**  
(Chickering, 1996)

# 三、朴素贝叶斯分类器

Instance ID	$A_1$	$A_2$	...	$A_m$	$C$
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
n					

$a_1$	$a_2$	...	$a_m$	$c=?$
-------	-------	-----	-------	-------

属性条件独立

$$P(a_1, a_2, \dots, a_m | c) = \prod_{i=1}^m P(a_i | c)$$

朴素贝叶斯分类器

$$c(x) = \arg \max_{c \in C} \frac{P(c) \prod_{i=1}^m P(a_i | c)}{\sum_c P(c) \prod_{i=1}^m P(a_i | c)}$$

分类：去分母

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | c)$$



# 三、朴素贝叶斯分类器

Instance ID	$A_1$	$A_2$	...	$A_m$	$C$
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
$n$					

$a_1$  $a_2$ ... $a_m$  $c=?$


## 朴素贝叶斯分类器

### Naive Bayes (NB)

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i|c)$$

$$P(c) = \frac{\sum_{j=1}^n \delta(c_j, c) + 1}{n + n_c}$$

$$P(a_i|c) = \frac{\sum_{j=1}^n \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^n \delta(c_j, c) + n_i}$$



### 三、朴素贝叶斯分类器

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No
15	Sunny	Cool	High	Strong	?

### 三、朴素贝叶斯分类器

$$c(x) = \arg \max_{c \in \{yes, no\}} P(c)P(sunny|c)P(cool|c)P(high|c)P(strong|c)$$

- 根据数据库，可以计算出上式需要的各项概率值
  - ◆  $P(yes)=9/14=0.64$
  - ◆  $P(no)=5/14=0.36$
  - ◆  $P(strong|yes)=3/9=0.33$
  - ◆  $P(strong|no)=3/5=0.60$
  - ◆ ...
- 求 $c(x)$ 
  - ◆  $P(yes)P(sunny|yes)P(cool|yes)P(high|yes)P(strong|yes)=0.0053$
  - ◆  $P(no)P(sunny|no)P(cool|no)P(high|no)P(strong|no)=0.0206$
  - ◆  $c(x) = no$

# 三、朴素贝叶斯分类器

Knowl Inf Syst (2008) 14:1–37  
DOI 10.1007/s10115-007-0114-2

SURVEY PAPER

## Top 10 algorithms in data mining

Xindong Wu · Vipin Kumar · J. Ross Quinlan · Joydeep Ghosh · Qiang Yang · Hiroshi Motoda · Geoffrey J. McLachlan · Angus Ng · Bing Liu · Philip S. Yu · Zhi-Hua Zhou · Michael Steinbach · David J. Hand · Dan Steinberg

Received: 9 July 2007 / Revised: 28 September 2007 / Accepted: 8 October 2007

Published online: 4 December 2007

© Springer-Verlag London Limited 2007

**Abstract** This paper presents the top 10 data mining algorithms identified by the IEEE International Conference on Data Mining (ICDM) in December 2006: C4.5,  $k$ -Means, SVM, Apriori, EM, PageRank, AdaBoost,  $k$ NN, Naive Bayes, and CART. These top 10 algorithms are among the most influential data mining algorithms in the research community. With each algorithm, we provide a description of the algorithm, discuss the impact of the algorithm, and review current and further research on the algorithm. These 10 algorithms cover classification, clustering, statistical learning, association analysis, and link mining, which are all among the most important topics in data mining research and development.

# 三、朴素贝叶斯分类器

Machine Learning, 29, 131–163 (1997)

© 1997 Kluwer Academic Publishers. Manufactured in The Netherlands.

## Bayesian Network Classifiers\*

NIR FRIEDMAN

nir@cs.berkeley.edu

*Computer Science Division, 387 Soda Hall, University of California, Berkeley, CA 94720*

DAN GEIGER

dang@cs.technion.ac.il

*Computer Science Department, Technion, Haifa, Israel, 32000*

MOISES GOLDSZMIDT

moises@erg.sri.com

*SRI International, 333 Ravenswood Ave., Menlo Park, CA 94025*

**Editor:** G. Provan, P. Langley, and P. Smyth

**Abstract.** Recent work in supervised learning has shown that a surprisingly simple Bayesian classifier with strong assumptions of independence among features, called *naïve Bayes*, is competitive with state-of-the-art classifiers such as C4.5. This fact raises the question of whether a classifier with less restrictive assumptions can perform even better. In this paper we evaluate approaches for inducing classifiers from data, based on the theory of learning Bayesian networks. These networks are factored representations of probability distributions that generalize the


## 四、朴素贝叶斯分类器改进

Instance ID	$A_1$	$A_2$	...	$A_m$	$C$
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
...					
$n$					

$a_1$   $a_2$  ...  $a_m$   $c=?$

### 朴素贝叶斯分类器 Naive Bayes (NB)

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | c)$$




- 1) 处理算法：结构扩展
- 2) 处理数据：面向特征（特征选择、特征加权）  
面向实例（实例选择、实例加权）

## 四、朴素贝叶斯分类器改进

**结构扩展**  $c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | \Pi_{a_i}, c)$

$$P(c) = \frac{\sum_{j=1}^n \delta(c_j, c) + 1}{n + n_c}$$

$$P(a_i | \Pi_{a_i}, c) = \frac{\sum_{j=1}^n \delta(a_{ji}, a_i) \delta(\Pi_{a_{ji}}, \Pi_{a_i}) \delta(c_j, c) + 1}{\sum_{j=1}^n \delta(\Pi_{a_{ji}}, \Pi_{a_i}) \delta(c_j, c) + n_i}$$



**BNC**

**NP-Hard Problem**

**(Chickering, 1996)**


**Unrestricted not always Better**

**(Friedman et al., 1997)**



## 四、朴素贝叶斯分类器改进

### 结构扩展




**TAN** (Friedman et al., 1997); **SP** (Keogh & Pazzani, 1999)  
**FAN** (Jiang et al., 2005);



## 四、朴素贝叶斯分类器改进

### 结构扩展



$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i | a_{hp_i}, c)$$


$$P(a_i | a_{hp_i}, c) = \sum_{j=1, j \neq i}^m W_{ij} * P(a_i | a_j, c)$$

$$W_{ij} = \frac{I_P(A_i; A_j | C)}{\sum_{j=1, j \neq i}^m I_P(A_i; A_j | C)}$$

**HNB** (Zhang & Jiang, 2005; Jiang et al., 2009)

## 四、朴素贝叶斯分类器改进

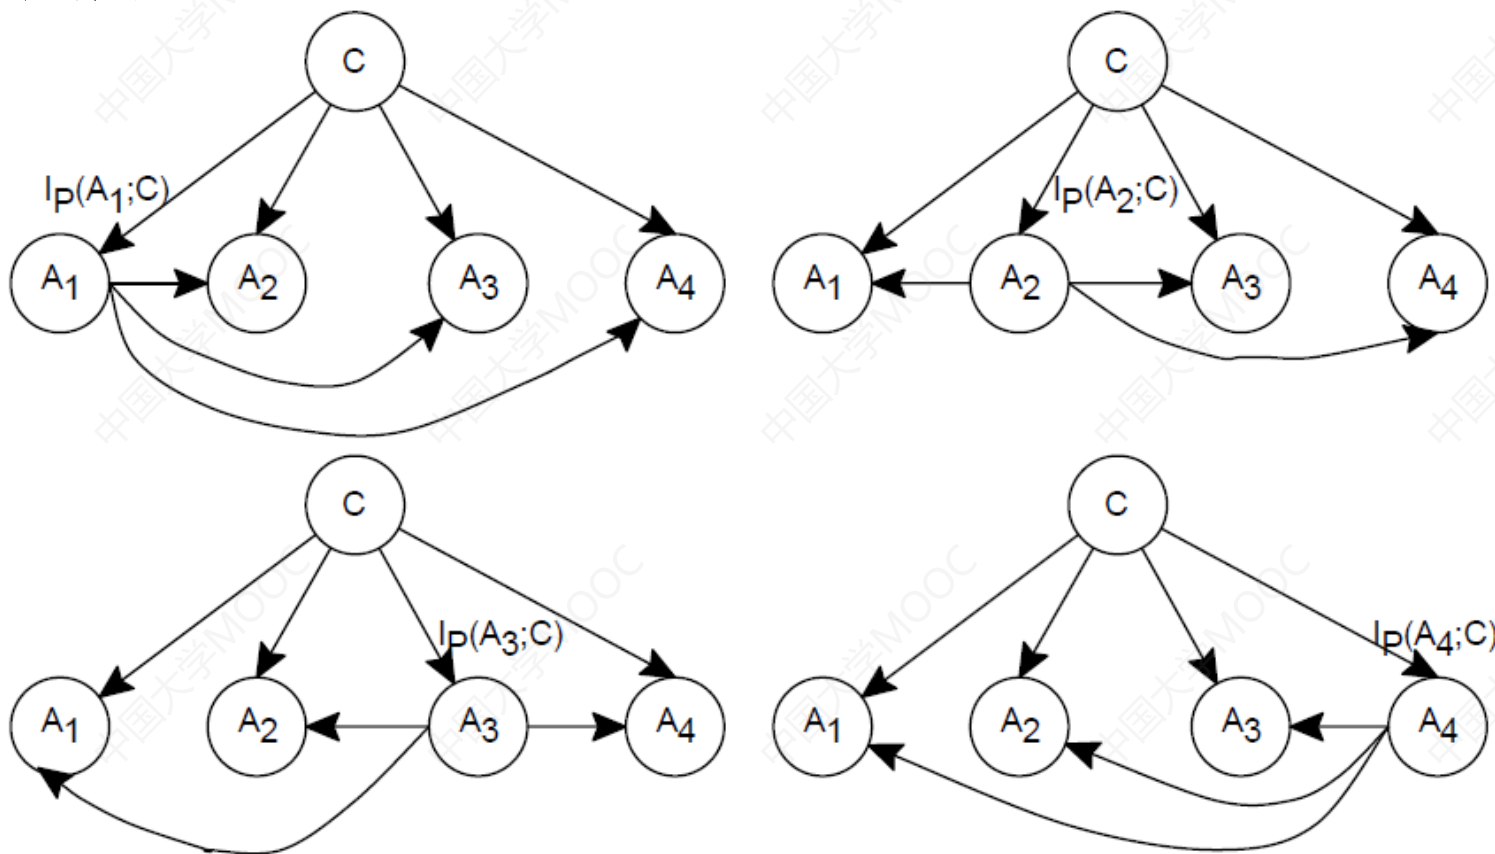
### 结构扩展



**AODE** (Webb et al., 2005)

## 四、朴素贝叶斯分类器改进





### 结构扩展



**WAODE** (Jiang et al., 2006; Jiang et al., 2012)

## 四、朴素贝叶斯分类器改进

### 结构扩展



**ATAN** (Jiang et al., 2012)


## 四、朴素贝叶斯分类器改进

### 特征选择

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^s P(a_i|c)$$

$$P(c) = \frac{\sum_{j=1}^n \delta(c_j, c) + 1}{n + n_c}$$

$$P(a_i|c) = \frac{\sum_{j=1}^n \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^n \delta(c_j, c) + n_i}$$



**SBC** (Ratanamahatana, 2003)

**SB** (Langley & Sage, 1994)


**ENB** (Jiang et al., 2005)

**RSNB** (Jiang et al., 2012)

**TCSNB** (Jiang et al., 2016)

## 四、朴素贝叶斯分类器改进

特征加权

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i|c)^{w_i}$$


$$P(c) = \frac{\sum_{j=1}^n \delta(c_j, c) + 1}{n + n_c}$$

$$P(a_i|c) = \frac{\sum_{j=1}^n \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^n \delta(c_j, c) + n_i}$$

**GRWNB** (Zhang & Sheng, 2004)

**DTWNB** (Hall, 2007)

**KLMWNB** (Lee et al., 2011)

**DFWNB** (Jiang et al., 2016)

**CFWNB** (Jiang et al., 2018)

**DEWNB** (Wu & Cai, 2011)

**CLLFWNB, MSEFWNB** (Zaidi et al., 2013)

## 四、朴素贝叶斯分类器改进

实例选择  
局部学习

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i|c)$$
$$P(c) = \frac{\sum_{j=1}^s \delta(c_j, c) + 1}{s + n_c}$$
$$P(a_i|c) = \frac{\sum_{j=1}^s \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^s \delta(c_j, c) + n_i}$$

**NBTree** (Kohavi, 1996)

**LBR** (Zheng & Webb, 2002)

**LWNB** (Frank et al., 2003)

**SNNB** (Xie et al., 2002)

**ICLNB** (Jiang et al., 2005; Jiang et al., 2008)

**DLNB** (Jiang et al., 2009); **CNNB** (Jiang et al., 2010)

## 四、朴素贝叶斯分类器改进

实例加权

$$c(x) = \arg \max_{c \in C} P(c) \prod_{i=1}^m P(a_i|c)$$

$$P(c) = \frac{\sum_{j=1}^n w_j \delta(c_j, c) + 1}{\sum_{j=1}^n w_j + n_c}$$

$$P(a_i|c) = \frac{\sum_{j=1}^n w_j \delta(a_{ji}, a_i) \delta(c_j, c) + 1}{\sum_{j=1}^n w_j \delta(c_j, c) + n_i}$$

**IWNB** (Jiang et al., 2010)

**CSNB** (Jiang et al., 2014)

**NB-MCT** (Jiang et al., 2015)

**BNB** (Elkan, 1997)

**DWNB** (Jiang et al., 2012)



教育部新世纪优秀人才支持计划 (NCET-12-0953)  
武汉市青年科技晨光计划 (2015070404010202)  
国家青年科学基金项目 (61203287)

# 贝叶斯网络分类器： 算法与应用

BEIYESI WANGLUO FENLEIQI:  
SUANFA YU YINGYONG

蒋良孝 李超群 编著



中国地质大学出版社  
ZHONGGUO DIZHI DAXUE CHUBANSHE

## 图书在版编目(CIP)数据

贝叶斯网络分类器:算法与应用/蒋良孝,李超群编著. —武汉:中国地质大学出版社,2015.  
12

ISBN 978-7-5625-3780-9

- I. ①贝…  
II. ①蒋… ②李…  
III. ①贝叶斯理论-应用-数据采集  
IV. ①TP274

中国版本图书馆 CIP 数据核字(2015)第 307024 号

## 贝叶斯网络分类器:算法与应用

蒋良孝 李超群 编著

责任编辑:张 琰 党梅梅

组稿编辑:张 琰

责任校对:周 旭

出版发行:中国地质大学出版社(武汉市洪山区鲁磨路388号)

邮政编码:430074

电 话:(027)67883511

传 真:67883580

E-mail: cbb@cug.edu.cn

经 销:全国新华书店

http://www.cugp.cug.edu.cn

开本:787毫米×1092毫米 1/16

字数:190千字 印张:7.5

版次:2015年12月第1版

印次:2015年12月第1次印刷

印刷:武汉市籍缘印刷厂

印数:1—500册

ISBN 978-7-5625-3780-9

定价:35.00元

如有印装质量问题请与印刷厂联系调换